

Guía de defensa del TFG — IA para maniobras orbitales

Documento de estudio para la defensa. Para cada tema: **QUÉ es** · **POR QUÉ se hizo así** (lo defendible) · **posibles preguntas** del tribunal. Documento vivo: se va ampliando según avanzamos. Lo "defendible" es lo que el tribunal puede preguntar; la "fontanería" de librerías (numpy, gymnasium, PPO interno) NO hace falta defenderla.

1. Fundamentos teóricos

Energía orbital específica — $\epsilon = -\mu/(2a)$

- **Qué:** energía total (cinética + potencial) por unidad de masa; solo depende del semieje a .
- **Por qué es negativa:** el "cero" de energía se toma en el infinito; una órbita ligada está atrapada en el pozo gravitatorio → energía negativa. Etiqueta el tipo de órbita: $\epsilon < 0$ **elipse**, $\epsilon = 0$ **parábola**, $\epsilon > 0$ **hipérbola**.
- **Si a disminuye, ϵ disminuye** (más negativa): órbita más pequeña = menos energía. El drag roba energía → ϵ baja → a baja → la órbita decae.
- **Posible pregunta:** "¿Por qué el satélite va más rápido al decaer pero tiene menos energía?" → la energía potencial cae más de lo que sube la cinética (paradoja del satélite).

Ecuación de la vis-viva — $v^2 = \mu(2/r - 1/a)$

- **Qué:** da la velocidad en cualquier punto de la órbita.
- **El nombre:** "fuerza viva" (Leibniz) = el término mv^2 (cinético); la ecuación no es más que la **conservación de la energía** de la órbita.

C3 (energía característica)

- **Qué:** $C3 = v_{\infty}^2$ (velocidad de exceso hiperbólico al cuadrado); energía por unidad de masa que "sobra" tras escapar del planeta de salida.
- **Por qué se usa:** depende solo de la trayectoria, no del cohete → medida estándar para comparar lanzamientos. $C3=0$ (parábola, escape justo); $C3>0$ (hipérbola).

Elementos orbitales / RAAN

- 6 elementos: **a** , **e** (tamaño/forma); **i** , **Ω** (orientación del plano); **ω** (orientación de la elipse); **ν** (posición sobre la órbita, el único que cambia en Kepler).
- **RAAN Ω :** ángulo, medido en el plano de referencia desde el punto Aries, que localiza el nodo ascendente (donde la órbita cruza el plano de sur a norte).

Cónicas parcheadas / esfera de influencia (SOI)

- **Qué:** el viaje interplanetario se trocea en tramos dominados por un solo cuerpo (hipérbola de escape → arco heliocéntrico → captura), cosidos en la SOI.
- **Por qué importa:** justifica calcular el Δv interplanetario como (arco de Lambert) — (velocidad del planeta), y es donde vive el C3.

Maniobras (Hohmann / Lambert / porkchop)

- **Hohmann:** mínimo Δv entre dos órbitas circulares coplanarias; 2 impulsos tangenciales.
 - **Lambert:** problema de **contorno** (fija r_1 , r_2 y tiempo de vuelo → busca la órbita); devuelve v_1 , v_2 → Δv . Tipo I ($< 180^\circ$) y tipo II ($> 180^\circ$), separados por la singularidad de los 180° (la franja blanca del porkchop).
 - **Porkchop:** mapa de $\Delta v/C3$ según fechas de salida/llegada (muchos Lambert encadenados).
-

2. Física — Atmósferas y validación

Modelo atmosférico por capas

- **Qué:** $\rho(h) = \rho_{\text{base}} \cdot \exp(-(h-h_{\text{min}})/H)$ por tramos; 9 cuerpos, 48 capas, 41 fronteras.
- **Decisión clave (defendible):** las alturas de escala H **no se ponen a mano**; se **derivan de la continuidad** entre capas. Las ρ_{base} (observadas) son el input.
- **Auto-comprobación:** si la H derivada se aleja de la física $RT/\mu g \rightarrow$ señal de densidad errónea (así se cazó el error de Neptuno).

Validación (factor de desviación)

- Júpiter **1,32x** (Galileo, in-situ), Saturno **1,06x** (Cassini, in-situ), Urano **1,15x**, Neptuno **1,2x** (Voyager reconstruido). Todo dentro de factor 2.
- **Saturno — dispersión RMS ~2x:** NO es error del modelo; es la **variabilidad latitudinal real** (Cassini midió de -85° a $+80^\circ$). El modelo da la **mediana** sobre latitudes, que es lo apropiado para el drag orbital integrado (el satélite recorre muchas latitudes).
- **RMS:** raíz cuadrática media; pondera más las desviaciones grandes que la mediana.

Reconstrucción hidrostática (Urano/Neptuno) — APORTACIÓN

- **Por qué hace falta:** no hay datos in-situ; Voyager 2 solo sobrevoló (no entró). Los datos vienen de **radio-ocultación:** la señal de radio atraviesa la atmósfera al ocultarse la sonda $\rightarrow$ da perfiles de **T y P**, solo donde el gas es denso (troposfera/estratosfera).
- **Método (defendible):** de ~ 9 puntos T-P de Lindal (las **anclas**) $\rightarrow$ perfil de densidad completo por **integración hidrostática** (= el mismo método de los GRAM de la NASA). Validado de forma cruzada contra los GRAM ($<2\%$).
- **Fiabilidad (honestidad):** alta de 0 a ~ 150 km (datos + anclas); datos hasta 262 km (Urano) / 300 km (Neptuno); por encima el modelo extrapola $\rightarrow$ capas altas = las menos fiables.

Error de Neptuno — APORTACIÓN

- La validación detectó ρ a 50 km $\sim 100\times$ baja $\rightarrow$ factor típico **8,0x $\rightarrow$ 1,2x** tras recalibrar. Demuestra que el método de validación **funciona** (caza errores que invalidarían todo).

Lección de las IAs generalistas — APORTACIÓN (honestidad)

- Datos de densidad de Júpiter de una IA generalista erraban **$\times 2500$** vs Galileo $\rightarrow$ regla del proyecto: solo fuentes primarias trazables.

3. Física — Propagador orbital

J2 (achatamiento planetario)

- Primer término zonal (y dominante) del potencial; el abultamiento ecuatorial rompe la simetría esférica $\rightarrow$ la órbita **precesa**. Efectos **periódicos** (oscilan, media nula) y **seculares** (regresión nodal Ω , precesión del perigeo ω).

Método de Cowell

- Integrar numéricamente la ecuación completa (gravedad central + J2 + drag) en vez de la solución analítica de Kepler. El drag usa la atmósfera **rotante** ($v_{\text{rel}} = v - \omega \times r$).

Validación vs Brouwer + escalado del error

- Regresión nodal simulada vs fórmula de Brouwer (1er orden): **$<1\%$** en J2 moderado.
- **El error crece $\propto J_2(R/a)^2$** (de $\sim 0,5\%$ en Tierra a $\sim 5\%$ en Júpiter/Saturno).

- **Por qué (defendible):** Brouwer es el primer término de una serie; el error relativo de truncar en 1er orden $\approx$ el parámetro de expansión $J_2(R/a)^2$. La que se desvía es la **fórmula analítica**, no la simulación (que integra la fuerza completa).

Acoplamiento drag-J2 — APORTACIÓN

- La simulación reproduce la desviación de **0,8°** (caso ISS) sobre Brouwer: el drag baja a, sube el movimiento medio n y acelera la precesión. Brouwer (sin drag) no lo captura → muestra de fidelidad del propagador.

Detección de reentrada + suite de tests

- Flag automático de reentrada + criterio de **fiabilidad de la pendiente** (ratio decaimiento/oscilación J_2).
- **Suite de verificación: 54 checks (6 por cuerpo × 9), todos superados.**
- **Limitación honesta:** en Júpiter/Saturno (J_2 alto), las órbitas muy bajas son inviables (la oscilación osculadora hunde el perigeo) → no es fallo, es física.

4. IA — Aprendizaje por Refuerzo (Bloque 4)

¿Qué es el RL?

- Aprender por **prueba y error con premios y castigos** (como adiestrar con chuches). El agente es un "piloto" que aprende a hacer la maniobra gastando el mínimo Δv .

Las 5 piezas (qué es cada una, y qué es en NUESTRO caso)

Imagina al agente como un piloto en un simulador:

- **Estado** — lo que el agente *ve* antes de decidir. En nuestro entorno: las dos órbitas (actual y objetivo) como radios normalizados [r_1/R_{REF} , r_2/R_{REF}]. Su "foto".
- **Acción** — lo que *decide hacer*. En nuestro caso: los dos impulsos tangenciales [Δv_1 , Δv_2] (dos números continuos). Su "decisión".
- **Recompensa** — la *nota* que recibe tras actuar: $-\text{error_de_llegada} - 0,01 \cdot \Delta v_{\text{total}}$. Cuanto más cerca de acabar circular en GEO gastando poco, mayor nota. Es lo que el agente intenta maximizar.
- **Episodio** — un *intento completo*: sale de LEO, da los dos impulsos y termina (1 paso). El agente repite cientos de miles de episodios para aprender.
- **Política** — la *estrategia aprendida*: la red neuronal que, dado el estado, elige la acción. Es lo que **PPO** va afinando.

Decisiones de diseño (DEFENDIBLES)

- **Estado = elementos limpios (a / energía), NO la altitud instantánea** → la altitud oscila por J_2 y confundiría al agente.
- **Recompensa = $-\Delta v$ - castigo por no llegar (+ bonus)** → su máximo coincide, por física, con la solución de Hohmann (gastar poco Y acertar).
- **Acción = impulsos tangenciales** → hace el aprendizaje tratable; Hohmann son justamente 2 impulsos tangenciales.
- **PPO (stable-baselines3)** → estándar, robusto, bueno para **control continuo** (los Δv son continuos).
- **Criterio de éxito: $\Delta v \leq 5\%$ del óptimo ($\leq 4,05$ km/s)** → margen razonable para afirmar "aprendió el óptimo".
- **Empezar por Hohmann LEO→GEO (Kepler)** → tiene **óptimo analítico** = juez objetivo; prueba de concepto antes de la Fase 2 (donde el RL sí es imprescindible).

Diseño del entorno: estructura y parámetros

Los cuatro scripts de la Fase 1 (carpeta ia/):

- `baselines.py` (**el JUEZ**): constantes (μ , R , altitudes) → funciones (velocidad circular, fórmula de Hohmann) → `main` que imprime el óptimo (LEO→GEO = 3,854 km/s).
- `env_hohmann.py` (**el MUNDO**): parámetros del entorno → la clase `HohmannEnv` con los **3 métodos de Gymnasium**: `__init__` (define el estado y la acción), `reset` (empieza un episodio, fija/sortea r_1 y r_2) y `step` (aplica la acción, simula la maniobra y calcula la recompensa) → `main` (la prueba a mano).
- `train_hohmann.py` (**ENTRENAR**): crea el entorno → crea el modelo PPO → configura el guardado del mejor modelo (`EvalCallback`) → entrena. *Defendible:* `ent_coef` (exploración) y `EvalCallback` (guardar el MEJOR modelo, no el último); el resto es uso estándar de la librería (fontanería).
- `evaluar_hohmann.py` (**EXAMINAR**): carga el mejor modelo → pone el entorno en LEO→GEO → pide la acción al agente (`predict`) → la ejecuta y la compara con el óptimo → dice si cumple el criterio ($\leq 5\%$).

Parámetros de diseño (el valor exacto es un "dial" que se ajusta entrenando; lo defendible es el PORQUÉ, no el número):

- $DV_MAX = 3$ **km/s** — techo de cada impulso (rango de la acción $[0, 3]$). *Por qué:* los impulsos óptimos son $\sim 2,4$ y $\sim 1,5$ km/s → 3 deja margen sin ser absurdo (un techo enorme haría perder tiempo explorando valores ridículos).
- **Recompensa SUAVE**: $-\text{error} - C_DV \cdot \Delta v$, con $W_ERROR = 1$ y $C_DV = 0,01$ — el peso del coste en Δv es **minúsculo a propósito**. *Por qué:* así **LLEGAR domina sobre ahorrar**; si el coste pesara mucho, el paisaje se aplanaría y el agente aprende a no hacer nada (la "esquina muerta" de las lecciones de abajo).
- **Sin premio escalón (sin bonus)** — *Por qué:* un salto de recompensa al bajar de cierto error desestabilizaba el aprendizaje (ver lecciones); la recompensa final es continua.
- $TOL_EXITO = 2\%$ — tolerancia para dar por buena la "llegada circular" al objetivo.

Arquitectura híbrida (la idea fuerte del proyecto)

- **RL** solo donde aporta (perturbaciones, atmósfera incierta: aerofrenado, desorbitado).
- **Solvers clásicos** donde hay óptimo conocido (interplanetario: Lambert/porkchop).
- **Capa LLM** (Claude API) que **orquesta** (elige la herramienta según el objetivo en lenguaje natural) y **explica**.
- **Por qué**: forzar RL en lo interplanetario (ya resuelto) sería un error metodológico.

Posibles preguntas del tribunal

- *¿Por qué usar RL para Hohmann si ya hay fórmula?* → es **prueba de concepto** sobre un caso con solución conocida; valida que el sistema de RL funciona antes del plato fuerte (aerofrenado, donde no hay fórmula).
- *¿Por qué la altitud no es el estado?* → oscila por J2 y confunde al agente.
- *¿Esto es RL de verdad o una optimización?* → la Fase 1 es un **bandit contextual** (RL de horizonte 1, honesto); la Fase 2 será RL secuencial completo.
- *¿Por qué PPO y no otro algoritmo (DQN, SAC, DDPG...)?* → **DQN** queda descartado: es para acciones **discretas** y aquí los Δv son **continuos**. **SAC/DDPG/TD3** sí son de control continuo, pero son *off-policy* y más **sensibles al ajuste** (pueden divergir). **PPO** es *on-policy*, **robusto y estable**, el estándar de facto y va bien "de fábrica". Como nuestro entorno es **barato** (física analítica, no integración cara por paso), la mayor eficiencia de muestras de SAC **no compensa** su fragilidad → PPO es la elección sensata.
- *¿Cómo evitas que el LLM alucine?* → anclado al código y a los datos del proyecto; toda cifra sale de cálculos sobre el modelo real (coherente con la regla de no fiarse de IAs generalistas).

Resultados de la Fase 1 y lecciones del entrenamiento

Resultado: el agente PPO aprende la transferencia LEO→GEO con un Δv a **0,03% del óptimo** de Hohmann (3,8528 vs 3,854 km/s) y llega a GEO circular con 0,08% de error (criterio: $\leq 5\%$). Es decir, **sin conocer la fórmula, descubre la maniobra óptima**.

El camino (muy defendible: demuestra dominio del diseño de recompensa):

- ***Reward hacking:** con la primera recompensa, el agente se **quedaba corto** (no llegaba a GEO) para ahorrar combustible → la recompensa premiaba mal.
- ***Esquina muerta:** al penalizar demasiado el Δv , la recompensa se **aplanó** y el agente aprendió a **no hacer nada** → el coste del Δv debe pesar MUCHO menos que llegar.
- ***Inestabilidad:** entrenar de más **descuadró** la política (PPO fluctúa en un óptimo fino) → solución: **guardar el mejor modelo** (EvalCallback), no el último.
- ***Recompensa suave:** quitar el "premio escalón" (un salto al bajar del 2% de error) estabilizó el aprendizaje.

Posible pregunta: ***"¿Por qué tanto ajuste de la recompensa?"** → porque el RL aprende lo que se le premia, no lo que uno quiere; diseñar bien la recompensa (que el óptimo sea el máximo y el paisaje tenga pendiente clara) **es** el trabajo.

Generalización (Agente 2): cualquier transferencia, en cualquier planeta — ADIMENSIONALIZAR

Qué es: la Fase 1 clava UN caso (LEO→GEO). El Agente 2 lo generaliza: **un único agente** que resuelve **cualquier** transferencia coplanaria (subir Y bajar) en **cualquier** cuerpo (los 9), sin reentrenar.

La clave — adimensionalizar (lo más vendible; es análisis dimensional puro):

- La transferencia de Hohmann **no tiene escala propia**: si divides los impulsos entre la velocidad circular inicial $v_{c1} = \sqrt{\mu/r1}$, los μ y $r1$ **se cancelan** y todo depende SOLO del ratio $R = r2/r1$.
- Por eso el estado del agente es **un solo número** (R , en escala logarítmica para tratar igual subir $R>1$ y bajar $R<1$) y la acción son los impulsos en unidades de v_{c1} .
- **Frase potente:** ***"el agente no aprende velocidades, aprende la FORMA de la maniobra"** (qué fracción de tu velocidad orbital gastar) — como un piloto que aprende "acelera al 140% del crucero", no "ve a 7,8 km/s".
- **Consecuencia:** entrenado una sola vez en unidades adimensionales, **clava Marte, Júpiter, la Luna o Mercurio SIN reentrenar** — solo se multiplica su respuesta por la v_{c1} real del planeta.

Resultado: exceso sobre el óptimo de Hohmann **< 1%** en el rango útil (ratios de 0,2 a 11), y la **invariancia de escala** demostrada: los 9 cuerpos caen en el MISMO punto para cada R .

Lecciones del entrenamiento (defendibles):

- **Error logarítmico, no lineal:** el error relativo lineal se disparaba en las bajadas profundas (~ 9) y reventaba la red de valor (el crítico) → no aprendía. El error en **escala logarítmica** es simétrico (subir/bajar) y acotado → lo arregló.
- **Límite físico en la acción:** topar el primer impulso por debajo del umbral de escape elimina un "castigo-acantilado" que saturaba al agente en un extremo.
- **Currículum:** ampliar el rango de R poco a poco (primero maniobras suaves) para que converja en un espacio de maniobras tan amplio.
- **Trade-off irreducible (honestidad):** clavar a la vez los dos extremos (subir y bajar 1:12) no se pudo; reforzar uno degradaba el otro → se eligió el modelo equilibrado.

Posibles preguntas del tribunal:

- ***"¿Por qué un solo agente vale para todos los planetas?"** → porque la gravedad no tiene escala propia (invariancia de escala): el problema solo depende del ratio de radios.

- *¿Por qué el aerofrenado NO es universal y este sí?* → porque las atmósferas SÍ tienen escala propia (densidad y altura de escala distintas) → el aerofrenado va con especialistas por planeta (sección 5).
- *Si el Agente 2 ya hace LEO→GEO, ¿para qué el Agente 1? ¿No sobra?* → no sobran, van en **escalada didáctica**: el **Agente 1** demuestra **precisión máxima** clavando UN caso fijo (0,03% del óptimo) → prueba que la tubería de RL puede igualar el óptimo analítico. El **Agente 2** demuestra **generalización** (cualquier órbita, cualquier planeta) a costa de algo de precisión (<1-2%). Son dos cosas distintas que se quieren enseñar: que el método *puede ser exacto* y que el método *puede generalizar*. El 1 es la prueba de concepto; el 2, el salto conceptual (adimensionalización).

Extensión 3D (Agente 4): transferencias con CAMBIO DE PLANO

Qué es: extiende el Agente 2 a TRES dimensiones — ahora la órbita destino, además de otro radio, está **inclinada** un ángulo Δi . El agente hace la transferencia de Hohmann Y gira el plano, repartiendo el giro entre los dos impulsos.

Física clave (defendible):

- Girar el plano cuesta $\Delta v = 2 \cdot v \cdot \sin(\Delta i/2)$ → es **más barato donde se va más lento** (en el apogeo). Por eso el óptimo mete **casi todo el giro en el 2.º impulso**.
- Cada impulso es un **vector**: parte tangencial (cambia la órbita, la Hohmann de siempre) + parte fuera del plano (gira) → se suman por la **ley del coseno** (de ahí el coste combinado). El juez (`baselines.delta_v_hohmann_plano`) halla el reparto óptimo.
- *Número emblemático:* LEO→GEO con $28,5^\circ$ → el óptimo reparte **$\sim 2^\circ$ abajo + $\sim 26^\circ$ arriba** (justo lo que hacen las misiones GTO→GEO reales).

Diseño: acción **vectorial 4D** (el agente da las 2 componentes de cada impulso; NO se le dice cómo repartir el giro, lo **descubre solo**). Adimensional como el Agente 2 (estado $[\log R, \Delta i]$) → **invariancia de escala 3D**. Alcance: solo **subir** con cambio de plano (caso real GTO→GEO; bajar + girar es raro y carísimo).

Resultado: exceso < **2%** sobre el óptimo en todo el rango (R hasta **11,94** —el mismo límite que el Agente 2— y Δi hasta 40°), llegando circular y a la inclinación pedida (< $0,3^\circ$); **Marte y Júpiter clavados sin reentrenar** (<1,2%). [Una versión anterior, con menos rango y currículum más corto, se quedaba en $\sim 4\%$; ver lección 4.]

Lecciones del tuning (ORO — tres encadenadas): 1. **El papel del coste cambia de 2D a 3D**. En 2D c_{DV} podía ser casi cero: llegar con 2 impulsos tangenciales **fija** la solución de Hohmann. En 3D hay **grados de libertad de sobra** (muchas maniobras llegan a la misma órbita inclinada con costes distintos) → el coste **debe pesar** para que el agente elija la barata (si no, despilfarra: salió +27%). 2. **El colapso por escape es recurrente — y la lección del Agente 2 se transfiere**. Al subir el coste, la política colapsó saturando un impulso hasta **escapar**. Solución: **topar los impulsos por debajo del umbral de escape** (lo mismo que el Agente 2). Detalle revelador: al topar el 1.er impulso, el colapso **se mudó al 2.º** → hubo que cerrar las dos puertas. 3. **Tuning gradual, no a saltos**. Subir los pesos de golpe ($\times 6$) y el coste $\times 25$ **desestabilizó** un entrenamiento que era estable → la forma correcta es subir el coste **poco a poco** hasta el punto dulce (quedó en $c_{DV}=0,05$, $5\times$ el del 2D). 4. **Más entrenamiento gana a restringir a la fuerza (la lección más bonita)**. Para bajar el exceso de $\sim 4\%$ a $\sim 2\%$ se probó primero **estrechar** los rangos de impulso (quitar espacio al agente, la receta del Agente 2). **Fracasó**: el agente sacrificaba la llegada (no completaba el giro en los Δi grandes, error de inclinación $8-15^\circ$). Lo que SÍ funcionó fue lo contrario: **ampliar** el problema (rango de R de 8 a 11,94) y **alargar el currículum** (etapa extra, $\sim 1,3$ M pasos) → bajó el exceso a **<2% Y** amplió el alcance, todo a la vez. *Lección: cuando el agente despilfarra, a veces la cura no es recortarle opciones sino darle más rango y más entrenamiento bien escalonado.* Modelo previo ($R \leq 8$, $\sim 4\%$) respaldado en `modelo_transfer3d/best_model_backup_R8.zip`.

Posible pregunta: *¿Por qué el agente 3D solo sube?*" → porque combinar bajada **y** cambio de plano es una maniobra rara y muy cara; centrarlo en subir (inyección a GEO/órbitas altas inclinadas) es el caso de uso real y acota el problema.

5. IA — Fase 2: Aerofrenado (aerobraking) multi-planeta

¿Qué es y por qué RL aquí?

- **Aerofrenado:** bajar el apogeo rozando la atmósfera en cada paso por el perigeo, casi sin combustible (técnica real: MGS, MRO, MAVEN...).
- **RL irremplazable:** no hay fórmula (atmósfera incierta, control en lazo cerrado) y **usa tu atmósfera de Marte validada**. A diferencia de la Fase 1 (1 paso), es **RL secuencial** (decenas de pasadas encadenadas).

El dilema y el diseño

- Perigeo bajo → frena rápido pero **riesgo de destrucción**; alto → seguro pero lento.
- **Estado:** [apogeo, perigeo, apogeo objetivo]. **Acción:** perigeo de la próxima pasada. **Recompensa:** progreso (apogeo que baja) – tiempo (por pasada) – fuel; +éxito; –destrucción.
- **Física por pasada (King-Hele):** $\Delta v \approx \frac{1}{2} \cdot (C_d \cdot A/m) \cdot \rho(\text{perigeo}) \cdot v_p \cdot \sqrt{2\pi \cdot a \cdot H}$, con ρ y H de la atmósfera validada. **Sin J2** (no quita energía → no afecta al aerofrenado).
- **¿De dónde sale esa fórmula y qué asume? (por si preguntan):** es la aproximación clásica de **King-Hele** para el frenado en UNA pasada. La idea: el drag solo importa cerca del **perigeo** (donde ρ es máxima; sube exponencialmente al bajar). Al integrar el impulso de arrastre a lo largo de ese arco, suponiendo **atmósfera localmente exponencial** (escala H) y que **una sola pasada cambia poco la órbita**, la integral se resuelve y aparece el factor $\sqrt{2\pi \cdot a \cdot H}$ = la "longitud efectiva" del trozo de atmósfera densa que la nave atraviesa. Es estándar en mecánica orbital (King-Hele, *Theory of Satellite Orbits in an Atmosphere*).
Defendible: evita integrar la órbita paso a paso → entorno **rápido** (PPO necesita $\sim 10^5$ – 10^6 pasos), a cambio de no resolver la órbita completa, que aquí no hace falta.

El criterio de peligro: PRESIÓN DINÁMICA, no altitud (la clave del multi-planeta)

- **Qué es:** la nave se destruye si la **presión dinámica** $q = \frac{1}{2} \cdot \rho \cdot v^2$ en el perigeo supera un límite q_{max} — NO a una altitud fija.
- **Por qué q y no la densidad (muy vendible):** lo que rompe la nave depende también de la **velocidad al cuadrado**. A igual densidad, en Júpiter (vas $\sim 12\times$ más rápido que en Marte) el calentamiento es $\sim 600\times$ mayor. La densidad sola engañaría; q lo captura. Y q es justo lo que controlan las **misiones reales** de aerobraking.
- $q_{\text{max}} = 0,6 \text{ N/m}^2$ = **valor real** (Mars Global Surveyor), no casero. Validación cruzada: el perigeo crítico que sale para Marte ($\sim 110 \text{ km}$) coincide con los $\sim 108 \text{ km}$ calibrados a mano antes.
- **Consecuencia:** el **corredor de perigeo seguro de cada planeta se deriva solo** de su atmósfera + q_{max} (nada a ojo) y **transfiere** entre cuerpos → permite un especialista por planeta con el mismo código.
- **Dónde se evalúa q :** en el **PERIGEIO** (ahí ρ y v son máximas). En el apogeo $\rho \approx 0 \rightarrow q \approx 0$, no pasa nada. Y la q del perigeo **baja durante el aerofrenado** aunque el perigeo esté fijo: la densidad no cambia, pero al encogerse la órbita la velocidad de paso baja (vis-viva) → el peligro es máximo **al principio** (órbita grande = paso rápido).

Cómo es un aerofrenado REAL (por si lo preguntan — 4 fases)

1. **Captura:** encendido de motor → órbita muy elíptica con el **perigeo ALTO** (sobre la atmósfera densa; MRO: $426 \times 44.500 \text{ km}$). Aún no roza la atmósfera. 2. **Walk-in:** con impulsos de motor en

el apogeo, baja el perigeo hasta meterlo en el corredor. NO se entra de golpe; se coloca a propósito. 3. **Aerofrenado principal:** cientos de pasadas bajando el apogeo, ajustando el perigeo pasada a pasada. ← **ESTO es lo que modela nuestro agente.** 4. **Walk-out:** encendido final para subir el perigeo fuera de la atmósfera y dejar la órbita estable.

Nuestro agente empieza en la fase 3 (perigeo ya en el corredor, apogeo alto); las fases 1, 2 y 4 son maniobras de motor estándar (no RL).

Resultado

- **Multi-planeta:** un **especialista por planeta** para los **7 cuerpos con atmósfera** (Venus, Tierra, Marte, Júpiter, Saturno, Urano, Neptuno). Cada uno resuelve **cualquier** escenario de su planeta (apogeo inicial y objetivo aleatorios): **50/50 escenarios** nuevos cada uno → aprende la **estrategia**, no memoriza un caso. Algo que **ninguna fórmula da**.
- Frente a una **estrategia tonta** (perigeo alto fijo, que frena lentísimo o ni llega), el agente apura el perigeo y llega en una fracción de las pasadas (en Marte: 134 vs 862).
- **Comportamiento emergente (vendible):** el agente no busca el perigeo mínimo, sino el **óptimo seguro** (deja margen frente a $q_{\max}$). El margen es **amplio donde la atmósfera ya frena con eficacia** (Urano, $q \sim 0,16$) y **ajustado donde necesita apurar** (Júpiter, $q \sim 0,40$). No se programó: emerge del aprendizaje.
- **Duración real** (sumando periodos): de ~ 2 semanas (Marte) a ~ 3 meses (Júpiter).

¿Cómo se valida si NO hay óptimo analítico? (PREGUNTA CLAVE muy probable)

En la Fase 1 hay un juez (la fórmula de Hohmann). En el aerofrenado **no existe fórmula óptima** → ¿cómo se sabe que el agente lo hace bien? Por **cuatro anclajes convergentes**: 1. **Frente a una baseline tonta** (perigeo alto fijo): el agente llega en una fracción de las pasadas (Marte: 134 vs 862) o llega donde la tonta ni termina. Mejora medible. 2. **Cruce con una calibración independiente:** el perigeo crítico que el modelo de presión dinámica deriva para Marte (~ 110 - 112 km) **coincide** con los ~ 108 km que se habían calibrado a mano por separado → dos caminos distintos dan lo mismo. 3. **Coherencia física:** el agente se queda **dentro del corredor de q** (nunca supera $q_{\max}$) y apura más donde puede y menos donde no → comportamiento físicamente sensato, no números arbitrarios. 4. **Realismo del orden de magnitud:** sale en **cientos de pasadas** y semanas-meses, igual que las misiones reales (MRO ~ 445 pasadas) → la escala es la correcta.

Frase para el tribunal: "no tengo un óptimo cerrado contra el que medir, así que valido por **convergencia**: mejora sobre la baseline, coincidencia con la calibración manual, coherencia física y realismo frente a misiones reales."

Lecciones del entrenamiento (defendible)

- **Agente miedoso:** un "acantilado" de castigo pegado al óptimo envenenaba la zona buena → el agente se iba a perigeo alto y no llegaba (timeout).
- **Desequilibrio de escala:** el -200 de destrucción ahogaba el $+10$ /pasada → PPO huía de lo profundo. SOLUCIÓN: dar **colchón** (peligro $112 \rightarrow 108$ km) + **castigo moderado** ($-200 \rightarrow -50$). Misma familia de lección que la Fase 1: la recompensa hay que escalarla bien.
- **El horizonte (gamma) — lección clave del multi-planeta:** con horizonte largo (cientos de pasadas) y el factor de descuento por defecto (0,99), el premio de éxito queda descontado a casi nada ($200 \cdot 0,99^{500} \approx 1,3$) y el agente se vuelve tímido → la **Tierra fallaba** (timeout). Subir gamma a **0,999** ($200 \cdot 0,999^{500} \approx 122$) hace visible ese premio lejano → 8/8. *Lección:* el descuento debe encajar con la longitud del episodio.

Alcance / limitaciones (honestidad)

- **Solo BAJA órbitas:** el drag solo quita energía; subir una órbita necesita motor (otra maniobra). Y el perigeo debe meterse en la atmósfera.

- **Especialistas por planeta** (7 cuerpos), NO un único cerebro universal: las atmósferas sí tienen escala propia (densidad, altura de escala), a diferencia de las transferencias. Un único agente multi-planeta necesitaría meter la densidad/presión sentida en el estado (extensión).
- **Júpiter (honestidad):** sale **operable según el modelo de arrastre**, pero **inviabile en la realidad** por factores no modelados (radiación letal, calentamiento a ~ 51 km/s). Mejor que un simple "no se puede".
- **Coeficiente balístico** $Cd \cdot A/m = 0,22 \text{ m}^2/\text{kg}$ = nave de ejemplo con mucha área; es **$\sim 5\text{-}10\times$ el de MGS/MRO** ($\sim 0,02\text{-}0,05$), por lo que nuestro aerofrenado es más ágil que las misiones reales (junto con un escenario de captura más modesto). Supuesto documentado.
- **J2 NO cambia la inclinación** (precesa Ω y ω ; i se mantiene). Lo que cambia i un poco es el drag con atmósfera rotante. Mantener i exacta = entorno **3D** con control fuera del plano (extensión).
- **Atmósfera NO rotante en el entorno del agente** (honestidad — posible pregunta del tribunal): el drag y la presión dinámica se calculan con la velocidad **inercial** (vis-viva), no con la **relativa al aire** $v_{rel} = v - \omega \times r$. *(Ojo: el propagador del Bloque 2 Sí usa v_{rel} ; esta simplificación es solo del entorno de RL.)* Justificación: (1) es **conservadora** $\rightarrow v_{inercial} > v_{rel}$ en órbita prógrada, así que **sobreestima** el drag y la $q \rightarrow$ el agente se cree el perigeo más peligroso de lo que es $\rightarrow$ margen de seguridad extra; (2) el entorno es **2D sin inclinación**, así que incluir ω obligaría a fijar la hipótesis "ecuatorial prógrada" (caso particular; en órbita polar $v_{rel} \approx v_{inercial}$) $\rightarrow$ hacerlo bien es el entorno 3D (extensión); (3) **no cambia ninguna conclusión**: el efecto es $\sim 5\%$ en Marte/Tierra, despreciable en Venus (rota lentísimo) y solo $\sim 25\%$ en Júpiter, que ya está excluido por inviable. Misma familia que la omisión de J2: simplificación declarada, no descuido.
- Atmósfera **determinista** $\rightarrow$ el óptimo es el borde (perigeo más profundo seguro). Con **incertidumbre atmosférica** el agente tendría que mantener un margen (extensión realista).

Agente 5: mantenimiento orbital (station-keeping) — IMPLEMENTADO

Qué es: el quinto agente. Mantiene una órbita operativa frente a las perturbaciones a lo largo del tiempo. Es un problema **temporal multi-paso** (la órbita se degrada poco a poco y hay que decidir cuándo/cuánto corregir), a diferencia de los otros agentes, que son de un solo impulso o una sola maniobra.

Qué corrige y qué NO (clave física, MUY preguntable):

- El **arrastre** baja el semieje y circulariza la órbita $\rightarrow$ el agente lo corrige con **re-boost** para mantener la geometría (a , e , i) dentro de una banda. ESTO es lo que hace.
- El **J2 NO degrada la geometría**: en media secular deja a , e , i constantes; solo **precesa la orientación** (Ω y ω). $\rightarrow$ **NO se combate**; se modela y se contabiliza, pero no se corrige. *(OJO: esto corrige el plan inicial, que hablaba de "compensar Ω y ω ".)* Corregir esa precesión sería fuera de plano y **carísimo/irrealista** — las órbitas heliosíncronas hasta la **aprovechan**.
- En la Luna y Mercurio (sin atmósfera) la geometría no se degrada $\rightarrow$ **nada que mantener**, excluidos (igual que en el aerofrenado).

Cómo: física **secular analítica** (rápida, sin Cowell por paso): $da/dt = -(Cd \cdot A/m) \cdot \rho \cdot v \cdot a$, con ρ del **modelo atmosférico validado**; la precesión de Ω se sigue con la **fórmula de J2 verificada vs Brouwer**. Episodio = **misión de duración fija**; objetivo: mantener en banda con el mínimo Δv . **Especialista por planeta** (como el aerofrenado: la atmósfera no es invariante de escala). La **franja de altitudes** de cada cuerpo **se deriva de su atmósfera** (donde mantener cuesta 2–250 m/s/año), como el corredor de perigeo del aerofrenado.

Resultado: los 7 cuerpos con atmósfera, **30/30** escenarios aleatorios cada uno. Ahorro frente a la estrategia ingenua **según el régimen**: Marte **$\sim 45\%$** (franja estrecha + altura de escala pequeña $\rightarrow$ el control fino importa), gigantes **$\sim 0\text{-}2\%$** (la física ya fija el Δv y la heurística es casi óptima). El agente **nunca es peor**.

Lecciones (ORO para la defensa):

- **El Δv de mantenimiento está casi FIJADO por la física** (repone la energía que el arrastre quita) → no se puede "ahorrar por arte de magia"; el ahorro es marginal y **honesto**. El valor real del agente es la **generalización**, no el ahorro.
- **Reward hacking → bonus de supervivencia:** con una recompensa solo negativa, al agente le salía a cuenta "**suicidarse**" (salirse pronto = un castigo único < acumular negativos toda la misión). Se arregló premiando **cada día** mantenido en banda.
- **El tope del re-boost se ata a la BANDA, no a la velocidad:** escalarlo por la velocidad circular hacía que en los gigantes un re-boost moviera el semieje **4x la banda** → se "pasaba de largo" (la heurística parecía fallar por **artefacto**, no por física). Se ató al ancho de banda vía $\Delta a \approx 2a \cdot \Delta v / v$. *(Bug detectado al evaluar y corregido: honestidad.)*
- **Validación bonita:** la regresión nodal sale **$\sim -5^\circ/\text{día}$ para una órbita tipo ISS**, que coincide con la **real** de la estación → la fórmula secular de J2 clava la precesión.

Preguntas del tribunal probables:

- *¿Por qué no corriges el J2?*" → porque J2 no degrada la geometría (a, e, i), solo gira la órbita; corregir esa rotación es fuera de plano y carísimo, no se hace en la práctica. Mantener la geometría = corregir el arrastre.
- *¿El agente ahorra combustible?*" → poco, y es honesto: el Δv lo fija la física. El valor es la generalización (un mismo diseño mantiene los 7 cuerpos).
- *¿Por qué un especialista por planeta y no uno universal?*" → como el aerofrenado: la atmósfera no es invariante de escala, a diferencia de las transferencias keplerianas.

6. Repaso de los scripts: qué defender y qué es "fontanería"

*Lectura transversal de los 9 scripts de ia/ (3 entornos + 3 train + 3 evaluar + baselines). La idea: si el tribunal abre un archivo, saber **qué líneas son decisiones tuyas** (defendibles) y cuáles son **uso estándar de librería** (no hay que defender).*

Lo que es FONTANERÍA (no hace falta defender, basta reconocerlo)

- `import gymnasium, spaces.Box, heredar de gym.Env` → es solo el "molde" estándar para que stable-baselines3 entienda tu entorno. No lo programaste tú.
- `PPO("MlpPolicy", ...), model.learn(), model.predict(), PPO.load()` → API de stable-baselines3. No reimplementas PPO; lo aplicas.
- `Monitor(env)` → solo registra la recompensa por episodio para ver el progreso.
- `np.clip, reescalados [-1,1]→[lo,hi], np.sqrt` → utilidades.
- **El algoritmo PPO por dentro** (clipping del ratio, ventaja, GAE...) → teoría de la librería; puedes citar qué es PPO pero no tienes que derivarlo.

Lo que SÍ es tuyo y defendible (transversal a los 3 agentes)

- **La formulación del problema como MDP:** qué metiste en el **estado**, qué es la **acción**, cómo es la **recompensa**. Esto es 100% diseño tuyo y es el corazón de la defensa (ya detallado en §4 y §5).
- `reset()` y `step()`: dentro de `step` vive **tu física** (vis-viva, elipse de transferencia, King-Hele, presión dinámica). Eso NO es de la librería; lo escribiste tú a partir de los Fundamentos.
- `baselines.py` **es el JUEZ, separado del agente:** el óptimo clásico (Hohmann) se calcula aparte y solo sirve para **puntuar** al agente. *Defendible:* el agente nunca "ve" la fórmula → cuando se acerca a ella, es que de verdad aprendió. `hohmann_adim(R)` es la versión adimensional (demuestra que el óptimo solo depende de R).

Detalles concretos del código que te pueden preguntar

- **seed=0 (reproducibilidad):** fija el azar para que el entrenamiento sea repetible. *Si preguntan "¿es suerte de la semilla?"* → no: el aerofrenado se reevaluó con **semillas nuevas y sale 50/50**; la transferencia generaliza a planetas nunca vistos. La estrategia es robusta, no un golpe de suerte.
- **deterministic=True en predict (al evaluar):** el agente toma su **acción media**, sin el ruido de exploración del entrenamiento → resultado fijo y reproducible. Al entrenar Sí explora (con ruido); al examinar, no.
- **EvalCallback con un eval_env aparte:** se evalúa en un entorno **distinto** del de entrenamiento y se guarda el **mejor** modelo visto (no el último). *Defendible:* evita quedarte con una política que empeoró por la inestabilidad de PPO (lección de la Fase 1).
- **MlpPolicy = red neuronal pequeña** (2 capas de 64 por defecto en SB3). *Si preguntan por la arquitectura:* es la estándar; el problema no necesita más. Se anotó que una red mayor [128,128] podría ayudar al extremo difícil de la transferencia (no se vio necesario).
- **ent_coef (0,01-0,02):** premio extra por **explorar** (mantener variedad de acciones) → evita que el agente se "cierre" pronto en una solución mala. Es un dial, lo defendible es el porqué.
- **Reescalar la acción [-1,1]** → rango físico: las redes neuronales trabajan mejor con entradas/salidas normalizadas en torno a 0 → el agente decide en [-1,1] y el entorno lo traduce a Δv reales o a una altitud de perigeo.

Específicos de cada entorno (lo más fino, por si tiran del hilo)

- **env_hohmann — aleatorio=False:** se entrena SOLO el caso fijo LEO→GEO (prueba de concepto que se clava al 0,03%). El modo **aleatorio=True** (cualquier r_1, r_2) aprende la tendencia pero no clava el extremo GEO (muy sensible al primer impulso) → se generalizó mejor por otra vía (el Agente 2 adimensional).
- **env_transfer — normalización FIJA con LOG_RMAX:** aunque el currículum entrene con un rango de R menor al principio, el estado se normaliza SIEMPRE con el rango pleno → la "escala" que ve el agente no cambia entre etapas ni al evaluar (coherencia). **Límites asimétricos DV1/DV2 a medida:** topar el 1.er impulso por debajo del umbral de escape ($0,40 < \sqrt{2}-1$) mete el **límite físico dentro de la acción** y elimina el "castigo-acantilado".
- **env_drag — _altura_para_q (bisección):** el corredor de perigeo de cada planeta se **deriva** de su atmósfera + q_{max} , no se pone a ojo. **Normalización por H_REF y V_REF:** divide longitudes y velocidades por escalas propias del planeta → los **mismos pesos de recompensa** valen en Marte y en Júpiter pese a tamaños y velocidades muy distintos. $\gamma=0,999$: horizonte largo (cientos de pasadas) → ver la lección del descuento en §5.

Específicos del entrenamiento / evaluación

- **train_transfer.py — currículum por etapas:** se reutiliza el **mismo** modelo entre etapas (`set_env, reset_num_timesteps=False`) ampliando el rango de R; el EvalCallback evalúa **siempre en el rango pleno** → "el mejor modelo" se mide donde de verdad importa.
- **evaluar_transfer.py — la demo estrella (Parte B):** coge el modelo entrenado SOLO en adimensional y lo prueba en Marte/Júpiter **sin reentrenar**, multiplicando su impulso por la v_{c1} real del planeta → es la prueba visible de la **invariancia de escala**.
- **evaluar_drag.py:** lanza N escenarios aleatorios (`reset(seed=s)`) del mismo planeta → demuestra que **generaliza dentro del planeta** (no memoriza un caso).

Pendiente de añadir según avancemos: Bloque 5 (capa LLM) y cualquier decisión nueva.